




Tema 4 - Arquitecturas paralelas multiprocesadores

Cátedra: Organización del Computador II
Lic. Juan Pablo Moreno


Niveles de Paralelismo



On-Chip


Como aumentar el rendimiento de un chip para que haga más cosas a al mismo tiempo?

- Paralelismo a nivel de instrucción, Pipeline, Pipeline Superescalar
- Las instrucciones se pueden reordenar y combinarse en grupos que luego son ejecutadas en paralelo sin cambiar el resultado del programa.
- El paralelismo a nivel de instrucción es transparente al programador
- No puede aprovechar el paralelismo presente a niveles más altos (por ejemplo sistemas transaccionales, simulaciones científicas)



On-Chip

Cuando un hilo de ejecución pierde una referencia de memoria en los cachés de nivel 1 y nivel 2, hay una larga espera hasta que el request de ese word se cargan en el caché, por lo que se genera un pipeline stall. Una solución es utilizar Multithreading





On-Chip

- El paralelismo a nivel de hilos o tareas aprovecha la ejecución de procesos independientes.
- Cada hilo puede ser un proceso de que es parte de un programa paralelo que ejecuta múltiples procesos, o un programa independiente.
- Cada hilo tiene todo el estado: instrucciones, datos, registros, etc.
- Permite que hilos distintos aprovechen las unidades funcionales inactivas por stalls




On-Chip

SMT (AMD) o Hyperthreading (Intel) es el proceso de una CPU que divide cada uno de sus núcleos físicos en núcleos virtuales, que se conocen como hilos. Esto se hace para aumentar el rendimiento y permitir que cada núcleo ejecute dos secuencias de instrucciones a la vez.

- Permite usar los recursos de un procesador con planificación dinámica para beneficiarse del paralelismo a nivel de Thread e Hilo.
- Con planificación dinámica y renombramiento de registros se pueden enviar instrucciones de hilos independientes sin importar las dependencias entre ellos.

On-Chip

- Simula dos procesadores lógicos dentro de un único procesador físico
- Mejora en el rendimiento del procesador, puesto que al simular dos procesadores se pueden aprovechar mejor las unidades de cálculo
- Schedulers independientes
- Duplica recursos que se utilizan frecuentemente



Single-Chip Multiprocessors




Figure 8-10. Single-chip multiprocessors. (a) A dual-pipeline chip. (b) A chip with two cores.




Figure 8-11. The logical structure of a simple DVD player contains a heterogeneous multiprocessor containing multiple cores for different functions.

Single-Chip Multiprocessors




Figure 8-12. An example of the IBM CoreConnect architecture.



Coprocesadores

Acercar la computadora agregando un segundo procesador especializado.

- Network Processors
- Media Processors
- Cryptoprocessors

MULTIPROCESSORS

Se denomina multiprocesador a un computador que cuenta con dos o más microprocesadores (CPUs). La idea de utilizar múltiples procesadores tanto para aumentar el rendimiento como para mejorar la disponibilidad.




Figure 8-17. (a) High-performance Shared Memory Multiprocessor with 16 CPUs. (b) Parallel Image Partitioning & Analysis by CPU cores.




Figure 8-18. (a) Scalable Multicomputer Architecture with Message-Passing Interconnection. (b) Bit-map Image Distribution across Local Private Memories.

Taxonomía de Flynn (1972)

La clasificación de Flynn se basa en dos conceptos: flujos de instrucciones y flujo de datos.

Una secuencia de instrucciones corresponde a un IP. Un sistema con n CPU tiene n IP, por lo tanto, n secuencias de instrucciones. Un flujo de datos consta de un conjunto de operandos.

Flujo Instrucciones	Flujo Datos	Siglas	Nombre	Ejemplos del Mundo Real
Único (1)	Único (1)	SISD	Single Instruction, Single Data	Máquina clásica de Von Neumann, procesadores antiguos (Pentium I).
Único (1)	Múltiple	SIMD	Single Instruction, Multiple Data	Supercomputadoras vectoriales (Cray-1), GPUs modernas.
Múltiple	Único (1)	MISD	Multiple Instruction, Single Data	Sistemas teóricos, tolerancia a fallos en naves espaciales.
Múltiple	Múltiple	MIMD	Multiple Instruction, Multiple Data	Multiprocesadores modernos, clusters de supercomputación.



MIMD


- Aprovecha paralelismo a nivel de threads
 - Puede proveer multiprocesamiento a una sola aplicación de alto rendimiento o como un multiprocesador multiprogramado.
 - Se pueden construir aprovechando procesadores comerciales
- Un típico ejemplo de MIMD son los clústeres
- Multicore
 - Múltiples procesadores en un único chip
 - Comparten recursos: Memoria, E/S

MIMD

Cada procesador está ejecutando su propio flujo de instrucciones.

Un proceso es un segmento de código que se puede ejecutar de forma independiente; el estado del proceso contiene toda la información necesaria para ejecutar ese procesador.

En un entorno multiprogramado.



MIMD Clasificación

Los multiprocesadores MIMD existentes se dividen en dos clases, dependiendo de la cantidad de procesadores involucrados, lo que a su vez dicta una organización de memoria y una estrategia de interconexión

- Memoria compartida centralizada
 - UMA, Uniform Memory Access
 - NUMA, NonUniform Memory Access
 - COMA, Cache Only Memory Access
- Multiprocesadores con memoria distribuida
 - Memoria distribuida físicamente
 - Requiere red de conexión con alto ancho de banda

MIMD Memoria compartida






Figure 8-24. Three bus-based multiprocessors. (a) Without caching. (b) With caching. (c) With caching and private memories.

MIMD Memoria Distribuida






MIMD Memoria Distribuida

- Multiprocesadores con memoria distribuida físicamente
- Se debe centralizar el sistema de memoria por cada procesador, por que, no podría soportar las demanda sin incurrir en una latencia de acceso excesivamente larga
- El mayor número de procesadores también plantea la necesidad de una interconexión de gran ancho de banda
- Por que distribuir la memoria entre los nodos?
 - Permite escalar el ancho de banda de la memoria si la mayoría de los accesos son a la memoria local en el nodo.
 - Reduce la latencia para los accesos a la memoria local.
- La desventaja se encuentra en que la comunicación de datos entre procesadores se vuelve algo más compleja y que requiere más esfuerzo en el software para aprovechar el mayor ancho de banda de memoria que ofrecen las memorias distribuidas.

Gracias!

An abstract graphic on the right side of the slide, consisting of several dark gray rectangular blocks arranged in a staggered, isometric pattern. Two blocks are highlighted: a light green one in the upper-middle section and a blue one in the lower-middle section.